

实验 3: fMRI 数据处理分析基础

2024 年 5 月 7 日

实验 3: fMRI 数据处理分析基础

1 实验简介

本实验通过开源工具与开源数据集, 探索 fMRI 大脑功能成像数据的组织、查看与分析。

通过本实验, 你将通过学习操纵真实脑影像数据, 掌握以下技能:

- 了解 fMRI 数据的国际通用标准;
- 掌握如何使用 Python 及开源工具包 Nilearn 进行医学影像查看、处理;
- 如何应用机器学习技术构建和评估脑影像的分类模型。

2 实验准备

首先, 你需要安装完成本实验所需的工具包。为了加快安装速度, 请确保 pip 包管理器已切换到国内源。本实验的依赖包列举如下:

- Nilearn: 用于查看和处理 fMRI 脑影像数据, 特别是建立脑成像相关的机器学习模型;
- pandas: 面向表格数据分析的 Python 库;
- Scikit-Learn: Python 机器学习库。

```
[1]: import pkgutil

# 检查 pandas 库是否已安装
if pkgutil.find_loader('pandas'):
    print('Pandas is available.')
else:
    !pip install pandas -i https://pypi.tuna.tsinghua.edu.cn/simple/
```

```
# 检查 Scikit-Learn 库是否已安装
if pkgutil.find_loader('sklearn'):
    print('Scikit-Learn is available.')
else:
    !pip install sklearn -i https://pypi.tuna.tsinghua.edu.cn/simple/

# 检查 Nilearn 库是否已安装
if pkgutil.find_loader('nilearn'):
    print('Nilearn is available.')
else:
    !pip install nilearn -i https://pypi.tuna.tsinghua.edu.cn/simple/
```

Pandas is available.

Scikit-Learn is available.

Nilearn is available.

[2]: # 忽略 Warning 输出

```
import warnings
warnings.filterwarnings("ignore")
```

3 初识脑影像数据

我们使用 Nilearn 自带的 MNI152 数据样例，学习 Nifti 文件的加载和简单处理。

实验报告要点：- 在实验报告中，请详细记录实验过程，包括代码及运行结果；- 除实验过程外，在报告的适当位置加入你对以下问题的理解（请结合本实验手册，并查阅第三方资料）：1. 什么是 Nifti 标准？Nifti 格式的数据是怎样组织神经影像数据的？2. 什么是神经影像数据标准模板？什么是 MNI-ICBM152 模板？MNI-ICBM152 模板对大脑坐标系是怎样规定的？3. 在脑影像数据分析过程中，为什么需要对成像数据进行平滑处理？

[3]: # 导入 MNI152 数据的路径

```
from nilearn.datasets import MNI152_FILE_PATH

# MNI152_FILE_PATH 是一个文件路径，首先不妨查看这个位置
print(f"Path to MNI152 template: {MNI152_FILE_PATH}")
```

Path to MNI152 template: C:\Users\Lenovo\anaconda3\lib\site-packages\nilearn\datasets\data\mni_icbm152_t1_tal_nlin_sym_09a_converted.nii.gz

Nifti (Neuroimaging Informatics Technology Initiative, 即神经影像信息学技术倡议) 是神经影像数据的一套完整的标准, 旨在加强神经影像领域的数据共享和学术合作。通过以下链接进一步了解 Nifti 相关信息。[Nifti - Neuroimaging Informatics Technology Initiative](#)


3.1 查看数据

Nilearn 提供了 plotting 模块, 用于查看神经影像数据。例如, 我们使用 `plot_anat` 函数查看 MNI152 样例数据。

```
[4]: from nilearn import plotting

plotting.plot_anat(MNI152_FILE_PATH)
```

```
[4]: <nilearn.plotting.displays._slicers.OrthoSlicer at 0x1e980057970>
```



plotting 模块包含了丰富的可视化功能函数, 通过以下链接了解它们。[Plotting brain images](#)

3.2 数据处理


尝试对数据进行平滑（smoothing）处理。我们将使用`nilearn.image.smooth_img`函数。

```
[5]: from nilearn import image

# smooth_img 函数返回一个 Nifti1Image 类型的内存对象
smooth_anat_img = image.smooth_img(MNI152_FILE_PATH, fwhm=3)

# 查看平滑后的图像
plotting.plot_anat(smooth_anat_img)
```

```
[5]: <nilearn.plotting.displays._slicers.OrthoSlicer at 0x1e98021bd30>
```




3.3 处理结果的存储和加载

```
[6]: # 保存处理结果到文件
smooth_anat_img.to_filename("smooth_anat_img.nii.gz")
```

```
[7]: # 重新加载并绘制
plotting.plot_anat("smooth_anat_img.nii.gz")
```


[7]: <nilearn.plotting.displays._slicers.OrthoSlicer at 0x1e98034b7f0>



4 构建脑影像处理机器学习模型

在实验中，我们将基于 Haxby 数据集构建一个机器学习分类模型，该模型在输入脑成像数据，输出预测结果（受试者当前注视的是人类面孔还是猫的图片）。

Haxby 数据集是一个 4-D 时间序列 fMRI 数据集，来自于人脸和物体表征的研究。在 Haxby 的研究中，包含 6 名被试，每名被试完成 12 组实验。在每组实验中，让被试观看 8 种物体类别的灰度图像，每组以 24 秒的休息时间间隔开来。每张图像呈现 500ms，紧接着是 1500ms 的刺激间隔。全脑 fMRI 数据以 2.5s 的像重复时间记录，一种刺激的 block 约含 9 个像，每张图像包含 40x64x64 个体素。



J.V. Haxby et al. “Distributed and Overlapping Representations of Faces and Objects in Ventral Temporal Cortex”, Science vol 293 (2001), p 2425.-2430. [Link](#)

实验报告要点：

- 在实验报告中，请详细记录实验过程，包括代码及运行结果；

- 除实验过程外，在报告的适当位置加入你对以下问题的理解（请结合本实验手册，并查阅第三方资料）：
 1. 简要介绍 Haxby 数据集及与之关联的认知神经科学研究；
 2. 如何查看 4D fMRI 数据？
 3. 构建脑影像分类机器学习预测模型需要注意哪些问题？
 4. 针对脑影像分类模型，你能想到哪些应用场景？

4.1 下载 Haxby 数据集

使用 `nilearn.datasets.fetch_haxby` 函数可以方便地将 Haxby 研究数据集下载到本地磁盘。

如果下载速度慢，可以通过以下链接下载文件，并解压到`%homepath%/nilearn_data`目录下。

数据下载链接：[\[Link\]](#)（访问码：4qmr）

```
[8]: from nilearn import datasets

# Haxby 数据集包含 6 名被试，在不指定下载哪一组的情况下，将默认下载第 2 名被试
# 如果数据已经下载过，那么将直接加载数据
haxby_dataset = datasets.fetch_haxby()

# 查看该数据集在本地的存储位置
print(f"Datasets are stored in: {datasets.get_data_dirs()}")
```

Datasets are stored in: ['C:\\Users\\Lenovo\\nilearn_data']

```
[9]: # 'func'是一组 nifti 文件名，这里取第一个文件
fmri_filename = haxby_dataset.func[0]

# 查看该文件的存放位置
print(f"First subject functional nifti images (4D) are at: {fmri_filename}")
```

First subject functional nifti images (4D) are at:

C:\Users\Lenovo\nilearn_data\haxby2001\subj2\bold.nii.gz

4.2 数据查看

由于数据是 4D 的（每个时刻包含很多 3D EPI 影像），我们无法直接使用 `nilearn.plotting.plot_anat` 函数进行可视化。

这里我们通过 `nilearn.image.mean_img` 计算得到一张对不同时刻的影像进行“平均”的影像。

Tip: `view_img` 函数得到的结果是交互式的，可以用鼠标拖拽蓝色十字，查看不同位置的脑影像。

```
[10]: from nilearn.image import mean_img

      plotting.view_img(mean_img(fmri_filename), threshold=None)
```


```
[10]: <nilearn.plotting.html_stat_map.StatMapView at 0x1e9804627c0>
```

Haxby 数据集还提供了一个腹侧颞叶皮层（Ventral temporal cortex）的 mask。通过 `plot_roi` 查看 mask 的位置。

```
[11]: mask_filename = haxby_dataset.mask_vt[0]

      # 可视化掩膜，也就是将原始图像作为背景，叠加 mask 区域
      plotting.plot_roi(mask_filename, bg_img=haxby_dataset.anat[0], cmap="Paired")
```

```
[11]: <nilearn.plotting.displays._slicers.OrthoSlicer at 0x1e98048ac70>
```



查看数据标签，也就是每个时刻被试者的行为状态。

```
[12]: import pandas as pd

# 加载被试的行为信息
behavioral = pd.read_csv(haxby_dataset.session_target[0], delimiter=" ")
print(behavioral)
```

	labels	chunks
0	rest	0
1	rest	0
2	rest	0
3	rest	0
4	rest	0
...
1447	rest	11
1448	rest	11
1449	rest	11
1450	rest	11
1451	rest	11

[1452 rows x 2 columns]

Haxby 数据集关联的任务是视觉识别任务，因此，每个标签记录了当前被试者看到的图片的内容。

通过以下代码查看标签的分类方法。

```
[13]: conditions = behavioral["labels"]

# 去除重复记录
print(conditions.unique())

['rest' 'scissors' 'face' 'cat' 'shoe' 'house' 'scrambledpix' 'bottle'
 'chair']
```

标签共包括 8 种图片内容，或者“rest”状态。简洁起见，我们只关注“face”和“cat”两个场景。

我们通过以下代码对数据进行过滤，仅保留“face”和“cat”有关的数据。

```
[14]: # 创建过滤条件掩膜
condition_mask = conditions.isin(["face", "cat"])
```



```

# 对标签进行过滤
conditions = conditions[condition_mask]

# 转换为 numpy 数组
conditions = conditions.values

# 查看数据长度
print(f"Label shape: {conditions.shape}.")

# 使用 index_img 对影像进行过滤
from nilearn.image import index_img
fmri_niimgs = index_img(fmri_filename, condition_mask)
print(f"Imageset shape: {fmri_niimgs.shape}.")

```

Label shape: (216,).

Imageset shape: (40, 64, 64, 216).


观察可知，筛选后的数据包含 216 个时刻的数据。如果要查看某一特定时刻的影像，只需使用 `index_img` 筛选即可。

```

[15]: # 查看某时刻的影像
plotting.plot_anat(index_img(fmri_niimgs, 215))

```

[15]: <nilearn.plotting.displays._slicers.OrthoSlicer at 0x1e9805c4670>




此外，还可以通过使用 `iter_img` 函数，查看连续的一组影像。



```
[16]: from nilearn.image import iter_img

fmri_niimgs_subset = index_img(fmri_niimgs, slice(0, 3))
print(fmri_niimgs_subset.shape)

for img in iter_img(fmri_niimgs_subset):
    plotting.plot_img(
        img, threshold=3, display_mode="x", cut_coords=1, colorbar=False
    )
```

(40, 64, 64, 3)





4.3 尝试创建模型

我们使用支持向量机（SVM）训练一个简单的模型，模型输入为 3D 影像（VT 皮质掩膜区域），输出为被试看到的物体。

首先定义模型。

```
[17]: from nilearn.decoding import Decoder
```

```
decoder = Decoder(
```

```
estimator="svc", mask=mask_filename, standardize="zscore_sample"
)
```

使用所有数据进行拟合。

```
[18]: decoder.fit(fmri_niimgs, conditions)
```

用训练好的模型进行预测。

```
[19]: prediction = decoder.predict(fmri_niimgs)
print(prediction)
```



```
['face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'cat'
 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'face' 'face' 'face'
 'face' 'face' 'face' 'face' 'face' 'face' 'cat' 'cat' 'cat' 'cat' 'cat'
 'cat' 'cat' 'cat' 'cat' 'face' 'face' 'face' 'face' 'face' 'face' 'face'
 'face' 'face' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat'
 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'face' 'face' 'face'
 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face'
 'face' 'face' 'face' 'face' 'face' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat'
 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat'
 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face'
 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'cat' 'cat' 'cat'
 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'face' 'face' 'face' 'face' 'face'
 'face' 'face' 'face' 'face' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat'
 'cat' 'cat' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face'
 'face' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'face'
 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'cat' 'cat' 'cat'
 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat'
 'cat' 'cat' 'cat' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face'
 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face' 'face'
 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat' 'cat']
```



为了更加直观，我们还可以查看部分影像及预测结果样例。

```
[20]: selected_indices = [0, 9, 20, 32]
fmri_niimgs_subset = index_img(fmri_niimgs, selected_indices)

for idx, img in enumerate(iter_img(fmri_niimgs_subset)):
```

```
plotting.plot_img(  
    img, threshold=3, display_mode="x", cut_coords=1, colorbar=False,  
    title=prediction[selected_indices[idx]]  
)
```





4.4 通过交叉验证方法评估模型效果

在一个标准的机器学习模型构建过程中，我们需要划分训练集、测试集，仅使用训练集数据进行训练，且仅在测试集上评估模型效果。

这里，我们使用最后 30 个 data point 作为测试集。

```
[21]: # 划分训练集、测试集
fmri_niimgs_train = index_img(fmri_niimgs, slice(0, -30))
fmri_niimgs_test = index_img(fmri_niimgs, slice(-30, None))
```

```

conditions_train = conditions[:-30]
conditions_test = conditions[-30:]

# 定义模型
decoder = Decoder(
    estimator="svc", mask=mask_filename, standardize="zscore_sample"
)

# 训练模型
decoder.fit(fmri_niimgs_train, conditions_train)

# 在测试集上获得预测结果
prediction = decoder.predict(fmri_niimgs_test)

# 在测试集上评估模型效果
prediction_accuracy = (prediction == conditions_test).sum() / float(
    len(conditions_test)
)
print(f"Prediction Accuracy: {prediction_accuracy:.3f}")

```

Prediction Accuracy: 0.767

与一般机器学习模型的构建一样，我们还可以借助 `scikit-learn` 包，使用 K 折交叉验证方法评估模型效果。

```

[22]: from sklearn.model_selection import KFold
import warnings
warnings.filterwarnings("ignore")

cv = KFold(n_splits=5)

for fold, (train, test) in enumerate(cv.split(conditions), start=1):
    decoder = Decoder(
        estimator="svc", mask=mask_filename, standardize="zscore_sample"
    )
    decoder.fit(index_img(fmri_niimgs, train), conditions[train])
    prediction = decoder.predict(index_img(fmri_niimgs, test))

```

```

    predicton_accuracy = (prediction == conditions[test]).sum() / float(
        len(conditions[test])
    )
    print(
        f"CV Fold {fold:01d} | "
        f"Prediction Accuracy: {predicton_accuracy:.3f}"
    )

```

CV Fold 1 | Prediction Accuracy: 0.886

CV Fold 2 | Prediction Accuracy: 0.767

CV Fold 3 | Prediction Accuracy: 0.767

CV Fold 4 | Prediction Accuracy: 0.698

CV Fold 5 | Prediction Accuracy: 0.744

Nilearn 包的 Decoder 也提供了 K 折交叉验证功能。

```

[23]: n_folds = 5
       decoder = Decoder(
           estimator="svc",
           mask=mask_filename,
           standardize="zscore_sample",
           cv=n_folds,
           scoring="accuracy",
       )
       decoder.fit(fmri_niimgs, conditions)

```

```

[24]: # 检查每个 Fold 的性能指标
       print(decoder.cv_params_["face"])

```

```
{'C': [100.0, 100.0, 100.0, 100.0, 100.0]}
```

还可使用“留一法”，即在训练时每次留出一组作为验证集，所有其他组的数据作为训练集。

```

[25]: # 只选择“face”、“cat”的实验
       session_label = behavioral["chunks"][condition_mask]

```

```

[26]: from sklearn.model_selection import LeaveOneGroupOut

       cv = LeaveOneGroupOut()

```



```
decoder = Decoder(
    estimator="svc", mask=mask_filename, standardize="zscore_sample", cv=cv
)
decoder.fit(fmri_niimgs, conditions, groups=session_label)

print(decoder.cv_scores_)
```

```
{'cat': [1.0, 1.0, 1.0, 1.0, 0.9629629629629629, 0.8518518518518519,
0.9753086419753086, 0.40740740740740744, 0.9876543209876543, 1.0,
0.9259259259259259, 0.8765432098765432], 'face': [1.0, 1.0, 1.0, 1.0,
0.9629629629629629, 0.8518518518518519, 0.9753086419753086, 0.40740740740744,
0.9876543209876543, 1.0, 0.9259259259259259, 0.8765432098765432]}
```

4.5 查看模型权重

通过 `decoder.coef_` 可查看 SVM 模型的权重。每个体素一个系数。

```
[27]: coef_ = decoder.coef_
print(coef_)
```

```
[[-3.89376915e-02 -1.87166827e-02 -3.23027223e-02 -2.88747334e-02
 4.18696787e-02 1.10743982e-02 1.69998374e-02 -5.50954056e-02
-1.94204165e-02 -3.51227347e-02 1.08511681e-02 -1.28796909e-02
-1.54677084e-02 -3.78908998e-02 -3.69167840e-02 2.28087889e-02
 6.56416964e-03 -7.65753762e-03 1.67105832e-02 -8.02137755e-03
 5.29515654e-02 -8.17594607e-02 -6.36992178e-02 2.41325756e-02
 4.59874916e-02 -2.22603142e-02 -1.77309364e-02 2.22197290e-02
-9.53184412e-03 5.76047658e-02 2.14300211e-02 -9.14227736e-02
 4.03660748e-03 -2.89276009e-02 -3.89030724e-02 -3.35114396e-02
 2.21396058e-03 8.73132450e-03 -3.37416625e-02 -2.41275823e-02
-6.81648703e-02 1.65406612e-02 2.70783862e-02 -6.56852899e-03
-1.21663769e-02 5.47674473e-02 8.13285814e-03 3.60955646e-02
-1.52764432e-02 7.02913565e-02 1.28090839e-03 2.08007984e-02
-4.09926781e-03 3.72429614e-02 -3.77393519e-02 -1.03858769e-02
-2.38237998e-02 -5.48880033e-02 4.43026847e-02 -1.47419267e-01
-2.34042309e-02 1.87113551e-02 6.65858173e-02 -9.07602948e-02]
```

-1.22033551e-02	-2.95655393e-03	3.22091719e-02	-3.04054082e-02
6.15345375e-02	1.12248738e-02	1.93774715e-02	-1.30541742e-02
4.42975695e-02	-2.23066221e-02	6.88147064e-02	1.69390082e-02
1.78947266e-02	1.00274909e-02	2.99186443e-02	-2.52170794e-02
1.06153452e-02	-6.31955274e-03	2.21515214e-03	-2.23349123e-02
1.42561009e-02	-1.53123664e-02	-1.98226768e-02	-4.32637932e-02
-4.55125554e-02	3.41589273e-02	-2.79199202e-02	-2.80909099e-02
-3.70158923e-02	-5.71450744e-02	-6.98948421e-02	3.20175436e-03
-8.35451135e-03	-3.37628232e-02	3.04261597e-02	8.68457113e-03
6.19382450e-03	5.94180006e-02	9.07296304e-03	-1.48931682e-02
1.43558956e-02	-1.09026977e-02	2.67697872e-02	4.73787818e-02
-2.96432090e-02	3.09423446e-02	1.57928945e-02	-3.16720148e-02
-4.00105412e-02	-5.40261333e-02	2.82612250e-02	-1.12100968e-02
-5.45402703e-02	6.32178200e-02	-1.49997205e-02	2.47548040e-03
-4.56644074e-02	-1.83882880e-02	1.19956465e-02	-3.72172435e-02
-2.25526962e-03	4.58656637e-02	4.79167954e-02	2.51823329e-03
-4.31721930e-02	-5.35345059e-03	5.76994251e-02	7.40847734e-03
-3.20590355e-02	4.35700267e-03	1.68302995e-02	-2.92570098e-02
-2.24505356e-03	-8.30211317e-03	-1.00013090e-02	2.17135896e-02
-1.92615231e-03	-1.33222423e-02	-2.80300840e-02	-1.75293895e-02
-9.17792832e-03	-7.09944207e-03	-1.43033609e-02	5.06831589e-02
-1.84813733e-02	-4.71506499e-02	1.72569072e-02	-4.76642278e-02
-9.09082151e-04	4.00768230e-02	7.53995738e-02	7.25618380e-03
4.82604971e-02	4.50555181e-02	3.61201998e-02	-8.16481561e-03
1.95405729e-02	3.57884042e-02	4.89303914e-02	3.82974429e-02
6.23918887e-02	6.13675345e-02	-1.68752151e-02	1.66514280e-02
3.35521731e-02	-1.80212942e-02	4.46411139e-02	-3.53245630e-02
-3.67292034e-02	-4.62245046e-03	4.86829780e-02	3.39666640e-02
6.21723539e-03	1.73612235e-02	2.01697221e-02	2.17099156e-02
2.91413337e-02	2.37777037e-02	4.84698180e-02	-9.22623940e-03
-2.82637691e-02	-2.13781216e-02	1.80785589e-03	4.79687364e-02
-9.78894516e-03	1.11431567e-02	-1.65019268e-02	-2.89090540e-02
2.42851412e-02	-1.22347676e-02	-2.92870970e-02	-2.89844022e-02
-3.39533340e-02	-3.65273849e-03	2.65325084e-02	4.58043863e-02
-5.93380514e-02	-2.13630286e-02	-3.09407689e-02	5.50178119e-02
-3.38816368e-02	6.12602888e-03	1.41484344e-02	1.10216703e-02
5.33811524e-02	-2.12340029e-02	6.37421188e-03	-1.13075798e-02

-2.64225268e-02 -2.22398642e-02 -5.31921030e-02 -3.98652927e-02
-1.29727842e-01 -3.28092354e-02 -2.89712247e-02 -9.13473174e-03
-7.28723040e-03 -3.71051949e-02 -6.34907364e-02 2.04368630e-03
-8.26794696e-02 -6.71214943e-02 -2.29131089e-03 -2.33452316e-02
1.77914417e-02 -8.74666874e-02 -2.76477862e-03 -4.38275354e-02
-1.28050956e-02 2.78034482e-02 -4.32695443e-02 -3.22688208e-02
-2.28029175e-02 -2.57414954e-02 2.03623850e-02 -9.90248198e-03
-3.15033664e-02 -1.81419569e-02 -1.12323718e-03 -4.17432985e-02
-6.23480161e-02 2.54492346e-04 -6.73680025e-02 6.53967009e-02
1.06521268e-02 2.21983349e-02 -1.98728680e-02 -1.85520162e-02
4.05701932e-02 -3.02838533e-02 -8.10050496e-02 -7.42458176e-02
-4.93847900e-02 -1.01771912e-02 1.09407158e-02 -4.49254936e-02
2.92747930e-02 7.05309652e-03 5.07529402e-03 -4.84051936e-03
2.48754471e-03 3.00654713e-02 -2.63087317e-03 4.64687399e-03
7.90209621e-02 1.04857765e-02 1.68079723e-02 -4.36718179e-02
-1.08855713e-02 2.10241898e-02 -4.41965139e-02 3.16494772e-03
6.98670572e-02 8.61629778e-02 4.96235851e-02 6.03891153e-03
5.56494429e-02 -2.98919021e-02 4.13036569e-03 -3.21951487e-02
-3.14990555e-02 -5.31275834e-02 2.67256465e-02 3.14428557e-02
6.67091111e-03 -1.28703844e-02 2.20151254e-02 5.68523768e-02
2.25603808e-02 -2.04616769e-02 5.10341950e-03 2.85357769e-02
-1.81663939e-02 -8.48429180e-03 -3.18826007e-02 -1.18498055e-02
-4.10845952e-02 3.11776360e-02 9.63475013e-03 -8.25913490e-03
-3.12226452e-02 8.57656063e-03 -9.70188381e-03 1.32374474e-02
4.06446748e-02 8.23407462e-03 -3.27355028e-02 -4.33883630e-03
-1.75531114e-02 6.88841984e-03 3.45133333e-02 7.03298300e-02
2.16784891e-02 5.32225090e-03 8.17563743e-02 6.40062509e-02
-2.31146803e-03 -1.17558583e-02 1.75889236e-01 3.18130066e-02
-3.15886490e-02 3.34028506e-02 2.22781191e-02 1.00231906e-02
-4.74913187e-02 -2.12756820e-02 -3.98718146e-02 -6.04069059e-02
-4.65060680e-02 1.03003436e-02 -3.05702104e-04 1.80743515e-02
-1.75451611e-02 -8.72589671e-02 1.00662699e-01 4.46116235e-03
7.46870359e-02 -6.13411920e-02 2.81703945e-02 -1.40977833e-02
3.14638582e-02 -1.63834126e-02 3.66532599e-02 -5.15683696e-03
1.45093982e-02 6.35867176e-02 2.34598261e-02 8.81062253e-02
6.15344559e-02 -1.39361834e-02 2.07247387e-02 -3.15452992e-03
5.15425652e-02 -2.88767380e-02 1.60261837e-02 2.09702337e-02

```

-3.29172210e-02 -2.59461542e-02 -5.60400313e-02 -3.64627741e-02
 1.12882214e-02  2.17268096e-02 -1.51638791e-02 -7.82886880e-03
 2.42549933e-02  9.47013399e-02 -2.63031861e-02  1.17356365e-04
-5.24171416e-03  4.17988173e-02  8.85681117e-02  6.23651762e-03
 1.86601326e-02  1.54628572e-02  3.50535682e-03  6.20599761e-03
-1.19791134e-02  1.59526512e-02  7.12130414e-03 -8.93192540e-02
-3.54344991e-03  1.23477920e-02  3.03927754e-02 -2.37295213e-02
-3.82793016e-02 -4.98744631e-02  4.66896569e-02 -1.23292872e-02
-1.10332327e-02  2.18105706e-02  2.18719709e-02  2.63539399e-02
 1.05280045e-02  1.84618294e-02  8.36147869e-04 -6.65210147e-03
 3.49398287e-02  1.49352490e-02 -1.11599400e-02  6.69104640e-03
-2.00058820e-02 -3.99014826e-02  3.01871987e-02 -1.09866549e-02
-4.11780212e-02  2.72052371e-02  1.16425822e-02 -1.55501768e-02
 3.27701512e-02  3.95494538e-02  8.48733894e-03  2.19934951e-02
-9.88666567e-03 -3.61421575e-02 -4.77021466e-02  1.90075033e-02
-5.58286184e-02 -3.31739220e-02 -2.24913558e-02 -3.36175149e-02
-4.07355653e-02  1.08861029e-02  1.12810802e-02  7.63143076e-02
 4.04804847e-03  3.07013522e-02  2.89177565e-02  4.71608101e-03
 5.13384386e-02 -4.10364403e-02  1.23261689e-03 -2.50403775e-02
 5.85904527e-02 -1.04965591e-01 -4.41705064e-02  1.18520106e-02
-5.83203740e-02 -4.82245081e-02  9.17655348e-03  1.03259931e-02
-5.09188228e-03 -3.23390267e-02 -3.19386319e-02 -1.53770002e-02
-5.21212048e-02  1.55619953e-02  2.93484165e-02 -1.92528427e-02
 1.76693981e-02  2.67992145e-02  5.76553944e-02 -1.38163005e-02
 2.60399658e-02  1.50399507e-02  1.27424092e-02 -2.29244152e-02
-1.06665236e-02  9.81937753e-03 -4.77511697e-02  1.64243752e-02]]

```

```
[28]: print(coef_.shape)
```

```
(1, 464)
```

筛选出“face”类的系数。

```
[29]: coef_img = decoder.coef_img_["face"]
```

将模型权重保存到文件。

```
[30]: decoder.coef_img_["face"].to_filename("haxby_svc_weights.nii.gz")
```

使用脑影像作为背景，将模型权重进行可视化。

```
[31]: plotting.view_img(
        decoder.coef_img_["face"],
        bg_img=haxby_dataset.anat[0],
        title="SVM weights",
        dim=-1,
    )
```

```
[31]: <nilearn.plotting.html_stat_map.StatMapView at 0x1e9807760d0>
```

4.6 基线模型

一般地，我们可以将训练得到的模型与随机模型进行比较，以展示模型的可用性。

```
[32]: dummy_decoder = Decoder(
        estimator="dummy_classifier",
        mask=mask_filename,
        cv=cv,
        standardize="zscore_sample",
    )
dummy_decoder.fit(fmri_niimgs, conditions, groups=session_label)

# Now, we can compare these scores by simply taking a mean over folds
print(dummy_decoder.cv_scores_)
```

```
{'cat': [0.38888888888888895, 0.38888888888888895, 0.38888888888888895,
0.6111111111111112, 0.38888888888888895, 0.6111111111111112,
0.38888888888888895, 0.38888888888888895, 0.38888888888888895,
0.38888888888888895, 0.6111111111111112, 0.38888888888888895], 'face':
[0.38888888888888895, 0.38888888888888895, 0.38888888888888895,
0.6111111111111112, 0.38888888888888895, 0.6111111111111112,
0.38888888888888895, 0.38888888888888895, 0.38888888888888895,
0.38888888888888895, 0.6111111111111112, 0.38888888888888895]}
```