

《神经网络与深度学习》



深度生成模型 Deep Generative Models

<https://nndl.github.io/>


深度生成模型



AI绘画



AI配音



模仿学习



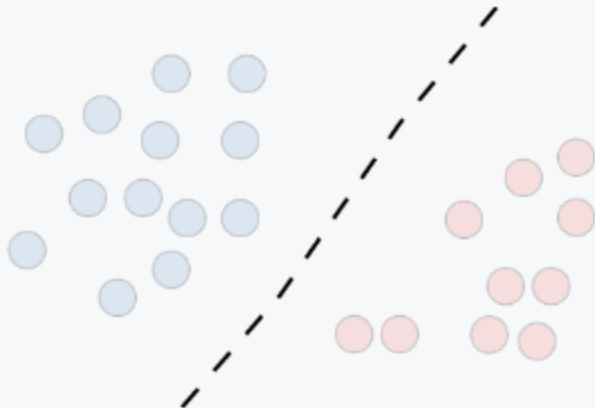
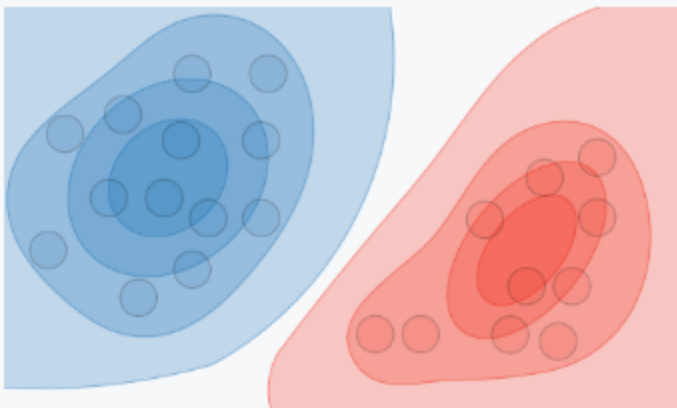
生物医药



生成模型

Generative Models


机器学习的两种范式

	Discriminative model	Generative model
Goal	Directly estimate $P(y x)$	Estimate $P(x y)$ to then deduce $P(y x)$
What's learned	Decision boundary	Probability distributions of the data
Illustration		
Examples	Regressions, SVMs	GDA, Naive Bayes

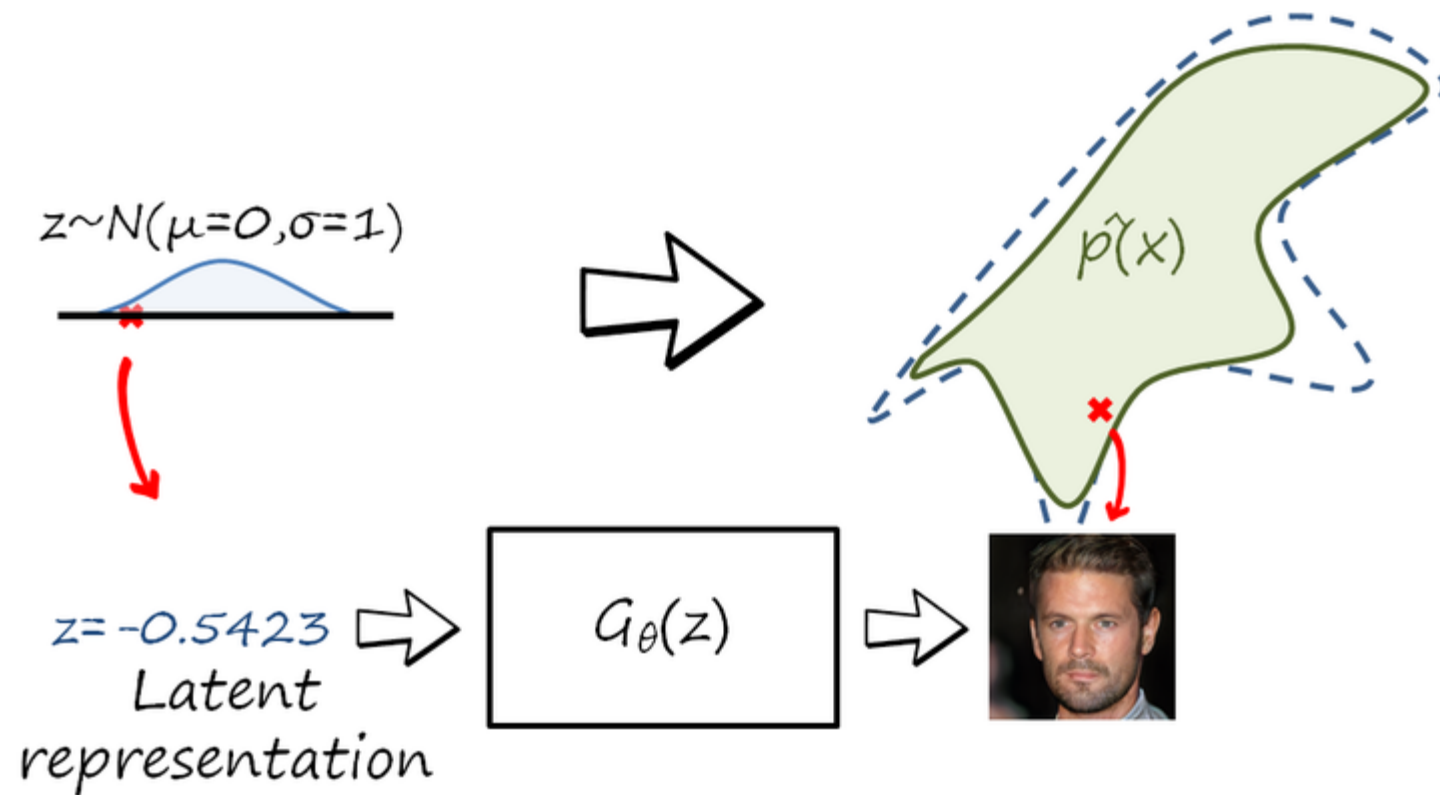
生成模型：一系列用于随机生成可观测数据的模型

▶ 生成模型包含两个步骤：

- ▶ 密度估计
- ▶ 采样



生成数据的另一种思路



显式密度模型和隐式密度模型

▶ 显式密度模型

- ▶ 显式地构建出样本的密度函数 $p(x|\theta)$ ，并通过最大似然估计来求解参数；
- ▶ 变分自编码器、深度信念网络

▶ 隐式密度模型

- ▶ 不显式地估计出数据分布的密度函数
- ▶ 但能生成符合数据分布 $p_{\text{data}}(x)$ 的样本
- ▶ 无法用最大似然估计

深度生成模型

▶ 深度生成模型就是利用神经网络构建的生成模型。

▶ 生成对抗网络 (Generative Adversarial Network, GAN)

▶ [Goodfellow et al., 2014]

▶ 变分自编码器 (Variational Autoencoder, VAE)

▶ [Kingma and Welling, 2013, Rezende et al., 2014]

▶ 基于流的方法 (Flow-based Method)

▶ 扩散模型 (Diffusion Model)

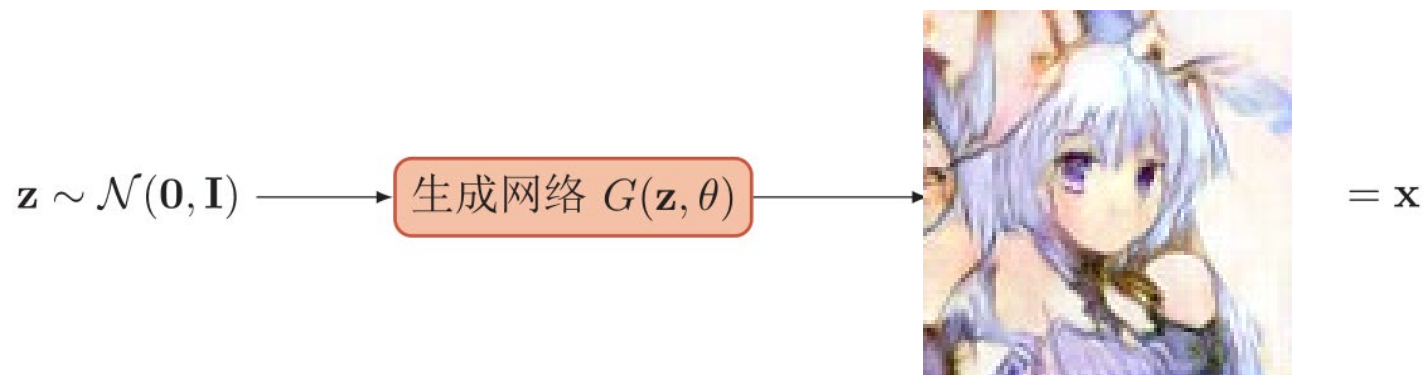


生成对抗网络

Generative Adversarial Network (GAN)

生成网络

- 生成网络从隐空间（latent space）中随机采样作为输入，其输出结果需要尽量模仿训练集中的真实样本。



如何学习生成网络？

生成网络示例




Each dimension of input vector represents some characteristics.

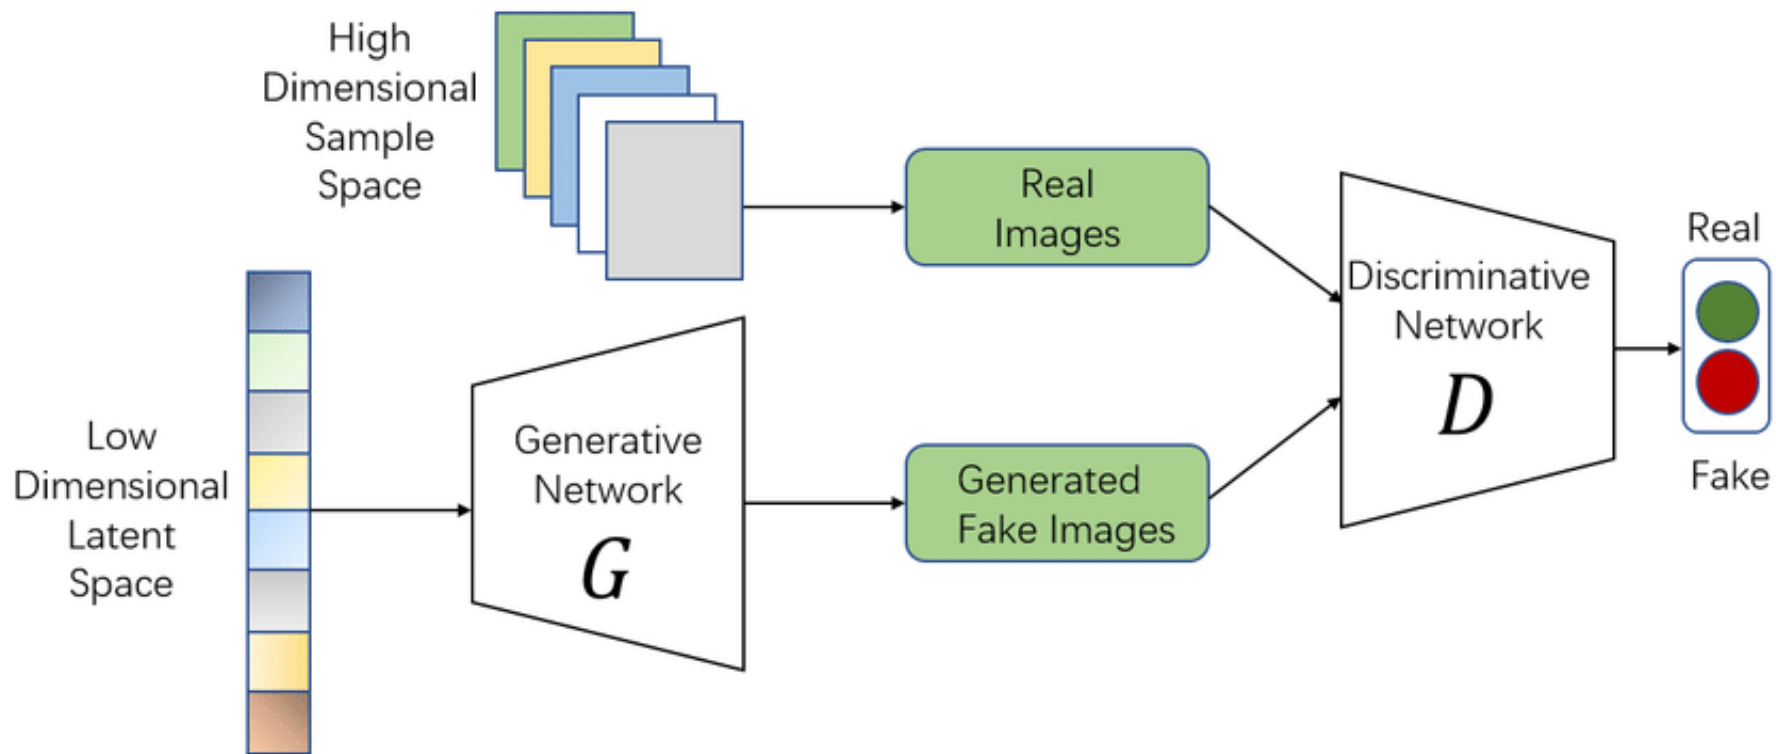


判别网络

- ▶ 判别网络的输入则为真实样本或生成网络的输出，其目的是将生成网络的输出从真实样本中尽可能分辨出来。



生成对抗网络



MiniMax Game

▶ 对抗训练

- ▶ 生成网络要尽可能地欺骗判别网络。
 - ▶ 判别网络将生成网络生成的样本与真实样本中尽可能区分出来。
-
- ▶ 两个网络相互对抗、不断调整参数，最终目的是使判别网络无法判断生成网络的输出结果是否真实。

对抗过程

生成网络
(student)

判别网络
(teacher)



MiniMax Game

► 判别网络

$$\max_{\phi} \mathbb{E}_{\mathbf{x} \sim p_r(\mathbf{x})} \left[\log D(\mathbf{x}; \phi) \right] + \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} \left[\log(1 - D(G(\mathbf{z}; \theta); \phi)) \right]$$

► 生成网络

$$\max_{\theta} \left(\mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} \left[\log D(G(\mathbf{z}; \theta); \phi) \right] \right)$$

► Minimax Game

$$\min_{\theta} \max_{\phi} \left(\mathbb{E}_{\mathbf{x} \sim p_r(\mathbf{x})} \left[\log D(\mathbf{x}; \phi) \right] + \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} \left[\log(1 - D(G(\mathbf{z}; \theta); \phi)) \right] \right)$$

训练过程

算法 13.1 生成对抗网络的训练过程

输入: 训练集 \mathcal{D} , 对抗训练迭代次数 T , 每次判别网络的训练迭代次数 K , 小批量样本数量 M

1 随机初始化 θ, ϕ ;

2 **for** $t \leftarrow 1$ **to** T **do**

 // 训练判别网络 $D(\mathbf{x}; \phi)$

3 **for** $k \leftarrow 1$ **to** K **do**

 // 采集小批量训练样本

4 从训练集 \mathcal{D} 中采集 M 个样本 $\{\mathbf{x}^{(m)}\}, 1 \leq m \leq M$;

5 从分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 中采集 M 个样本 $\{\mathbf{z}^{(m)}\}, 1 \leq m \leq M$;

6 使用随机梯度上升更新 ϕ , 梯度为

$$\frac{\partial}{\partial \phi} \left[\frac{1}{M} \sum_{m=1}^M \left(\log D(\mathbf{x}^{(m)}; \phi) + \log (1 - D(G(\mathbf{z}^{(m)}; \theta); \phi)) \right) \right];$$

7 **end**

 // 训练生成网络 $G(\mathbf{z}; \theta)$

8 从分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 中采集 M 个样本 $\{\mathbf{z}^{(m)}\}, 1 \leq m \leq M$;


9 使用随机梯度上升更新 θ , 梯度为

$$\frac{\partial}{\partial \theta} \left[\frac{1}{M} \sum_{m=1}^M D(G(\mathbf{z}^{(m)}; \theta), \phi) \right];$$

10 **end**

输出: 生成网络 $G(\mathbf{z}; \theta)$

Anime Face Generation



100 updates



1000 updates

Anime Face Generation



2000 updates




5000 updates

Anime Face Generation




10,000
updates




50,000
updates

生成对抗网络



一个具体的模型：DCGANs

- ▶ DCGAN (Deep Convolutional Generative Adversarial Networks)
- ▶ 判别网络是一个传统的深度卷积网络，但使用了带步长的卷积来实现下采样操作，不用最大汇聚（pooling）操作。
- ▶ 生成网络使用一个特殊的深度卷积网络来实现使用微步卷积来生成 64×64 大小的图像。




DCGANs

Real Images





Fake Images







模型分析

数据分布



In the end



模型分析

► 假设 $p_r(x)$ 和 $p_\theta(x)$ 已知，则最优的判别器为

$$D^*(\mathbf{x}) = \frac{p_r(\mathbf{x})}{p_r(\mathbf{x}) + p_\theta(\mathbf{x})}$$

► 目标函数变为

$$\begin{aligned}\mathcal{L}(G|D^*) &= \mathbb{E}_{\mathbf{x} \sim p_r(\mathbf{x})} \left[\log D^*(\mathbf{x}) \right] + \mathbb{E}_{\mathbf{x} \sim p_\theta(\mathbf{x})} \left[\log(1 - D^*(\mathbf{x})) \right] \\ &= \mathbb{E}_{\mathbf{x} \sim p_r(\mathbf{x})} \left[\log \frac{p_r(\mathbf{x})}{p_r(\mathbf{x}) + p_\theta(\mathbf{x})} \right] + \mathbb{E}_{\mathbf{x} \sim p_\theta(\mathbf{x})} \left[\log \frac{p_\theta(\mathbf{x})}{p_r(\mathbf{x}) + p_\theta(\mathbf{x})} \right] \\ &= D_{\text{KL}}(p_r \| p_a) + D_{\text{KL}}(p_\theta \| p_a) - 2 \log 2 \\ &= 2D_{\text{JS}}(p_r \| p_\theta) - 2 \log 2,\end{aligned}$$

$$\begin{aligned}D_{\text{JS}}(p \| q) &= \frac{1}{2} D_{\text{KL}}(p \| m) + \frac{1}{2} D_{\text{KL}}(q \| m) \\ m &= \frac{1}{2}(p + q)\end{aligned}$$

不稳定性：生成网络的梯度消失


$$\min_{\theta} \max_{\phi} \left(\mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} \left[\log D(\mathbf{x}, \phi) \right] + \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} \left[\log(1 - D(G(\mathbf{z}, \theta), \phi)) \right] \right)$$

在生成对抗网络中，当判断网络为最优时，生成网络的优化目标是最小化真实分布 $p_r(x)$ 和模型分布 $p_{\theta}(x)$ 之间的JS散度。

当两个分布相同时，JS散度为0，最优生成网络对应的损失为 $-2\log 2$ 。

使用JS散度来训练生成对抗网络的一个问题是当两个分布没有重叠时，它们之间的JS散度恒等于常数 $\log 2$ 。对生成网络来说，目标函数关于参数的梯度为0。

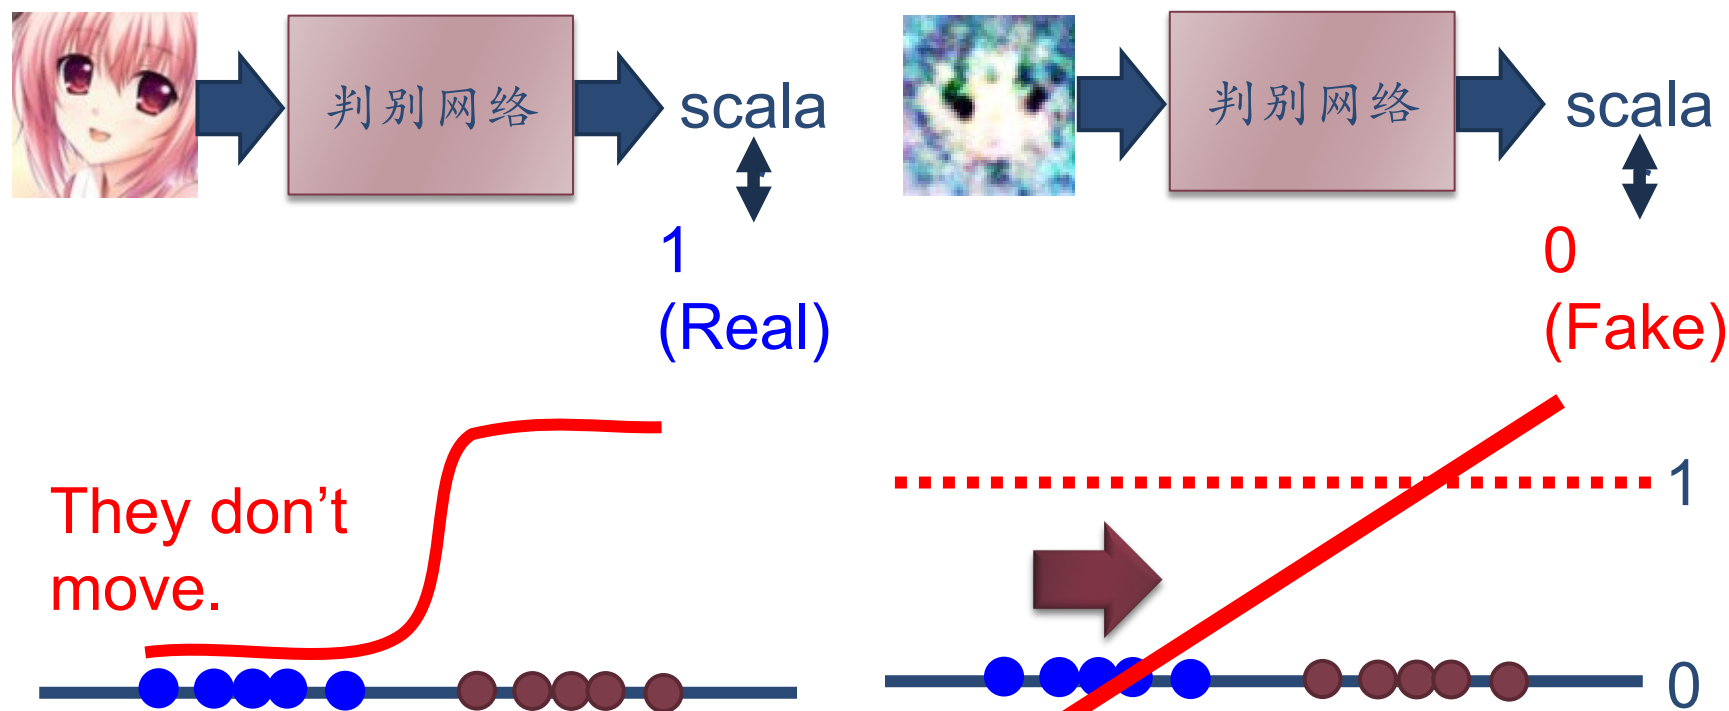
$$\frac{\partial \mathcal{L}(G|D^*)}{\partial \theta} = 0.$$



Least Square GAN (LSGAN)

● real
● generated

- Replace sigmoid with linear (replace classification with regression)





Wasserstein GAN

Wasserstein距离



- ▶ Wasserstein距离用于衡量两个分布之间的距离。

$$W_p(q_1, q_2) = \left(\inf_{\gamma(x,y) \in \Gamma(q_1, q_2)} \mathbb{E}_{(x,y) \sim \gamma(x,y)} [d(x,y)^p] \right)^{\frac{1}{p}}$$

- ▶ 其中 $\Gamma(q_1, q_2)$ 是边际分布为 q_1, q_2 的所有可能的联合分布集合， $d(x,y)$ 为 x 和 y 的距离，比如 ℓ_p 距离等。
- ▶ Wasserstein距离相比KL散度和JS散度的优势在于：即使两个分布没有重叠或者重叠非常少，Wasserstein距离仍然能反映两个分布的远近。

Wasserstein距离

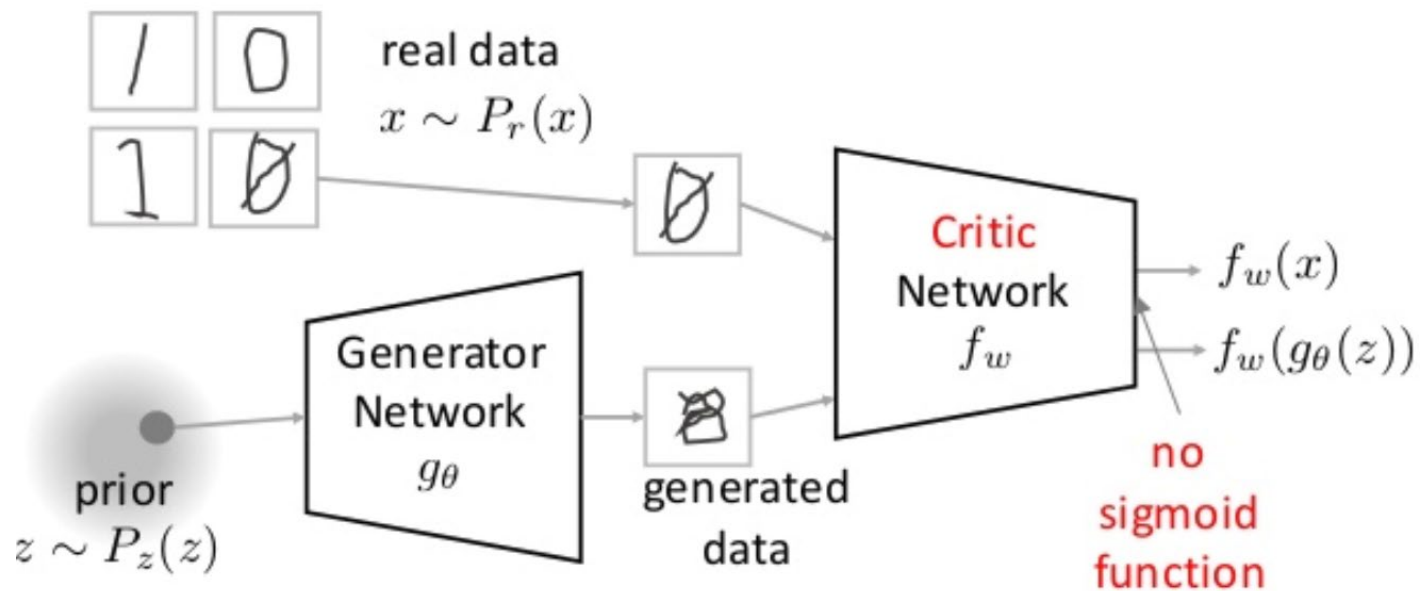
- 如果将两个分布看作是两个土堆，联合分布 $\gamma(x,y)$ 看作是从土堆 q_1 的位置 x 到土堆 q_2 的位置 y 的搬运土的数量。Wasserstein距离可以理解为搬运土堆的最小工作量，也称为推土机距离（Earth-Mover's Distance, EMD）。



Wasserstein GAN

$$\min_{\theta} \max_{w \in [-k, k]^l} \mathbb{E}_{x \sim P_r} [f_w(x)] - \mathbb{E}_{z \sim P_z} [f_w(g_{\theta}(z))]$$

k-Lipschitz Constraint






WGAN



DCGAN



~~batch normalization
constant number of filters at every layer~~



DCGAN

LSGAN

Original
WGAN

Improved
WGAN

G: CNN, D: CNN



G: CNN (no normalization), D: CNN (no normalization)



G: CNN (tanh), D: CNN(tanh)




DCGAN

LSGAN


Original
WGAN

Improved
WGAN


G: MLP, D: CNN



G: CNN (bad structure), D: CNN



G: 101 layer, D: 101 layer





GAN的扩展

条件生成

► 根据条件针对性的生成数据



“Girl with red hair and red eyes”

“Girl with yellow ribbon”




条件生成

Caption Generation

Given
condition:



“A young
girl is
dancing.”




Chat-bot

Given
condition:

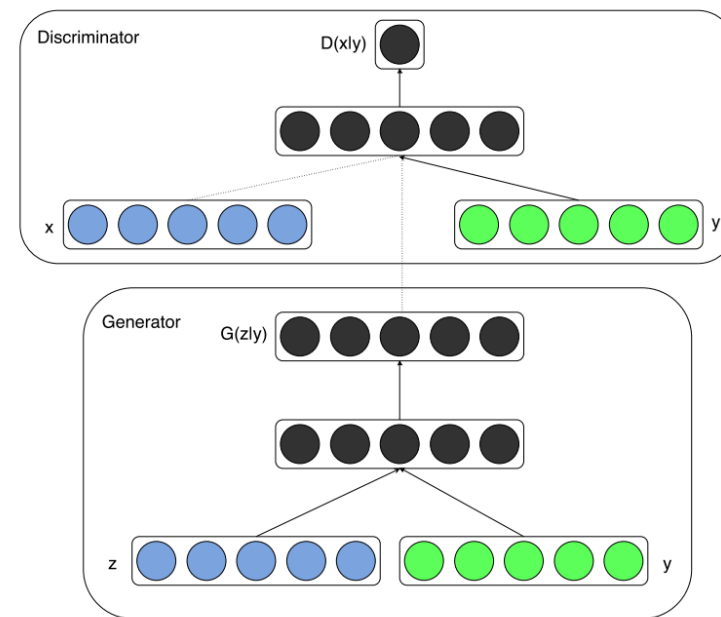
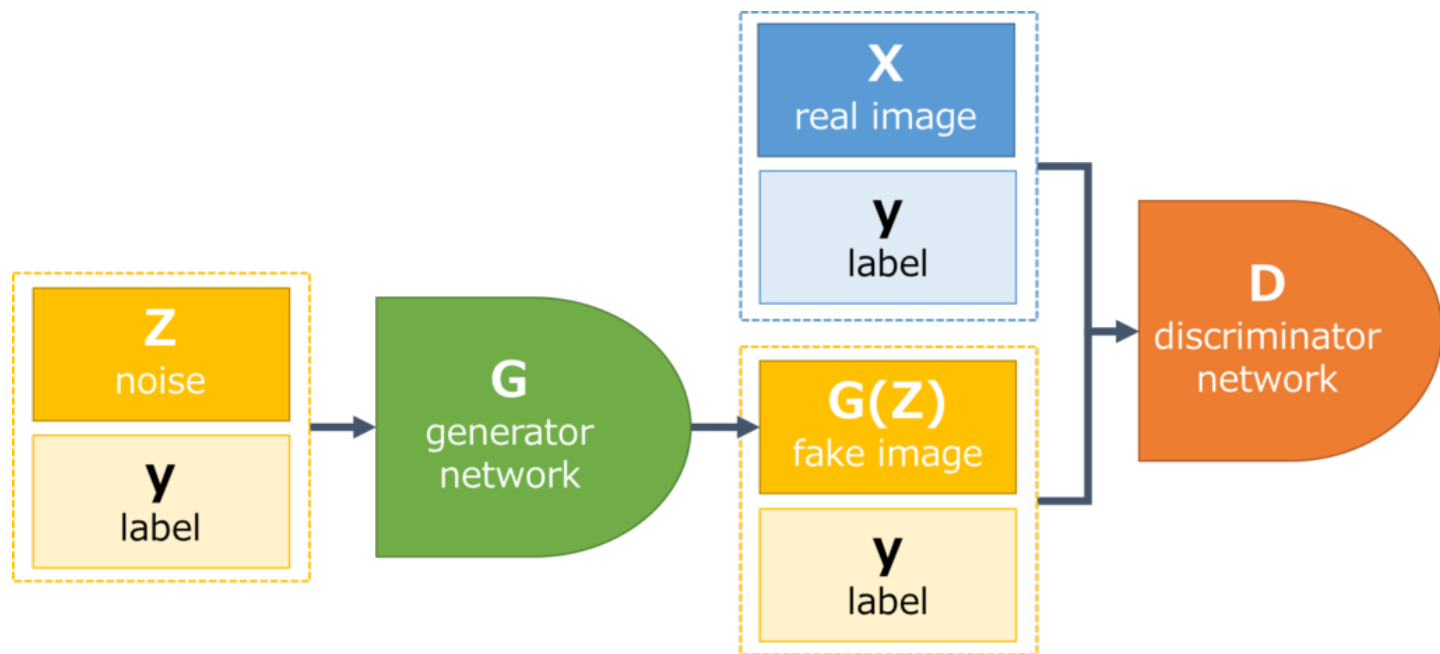



“Hello”

“Hello. Nice
to see you.”

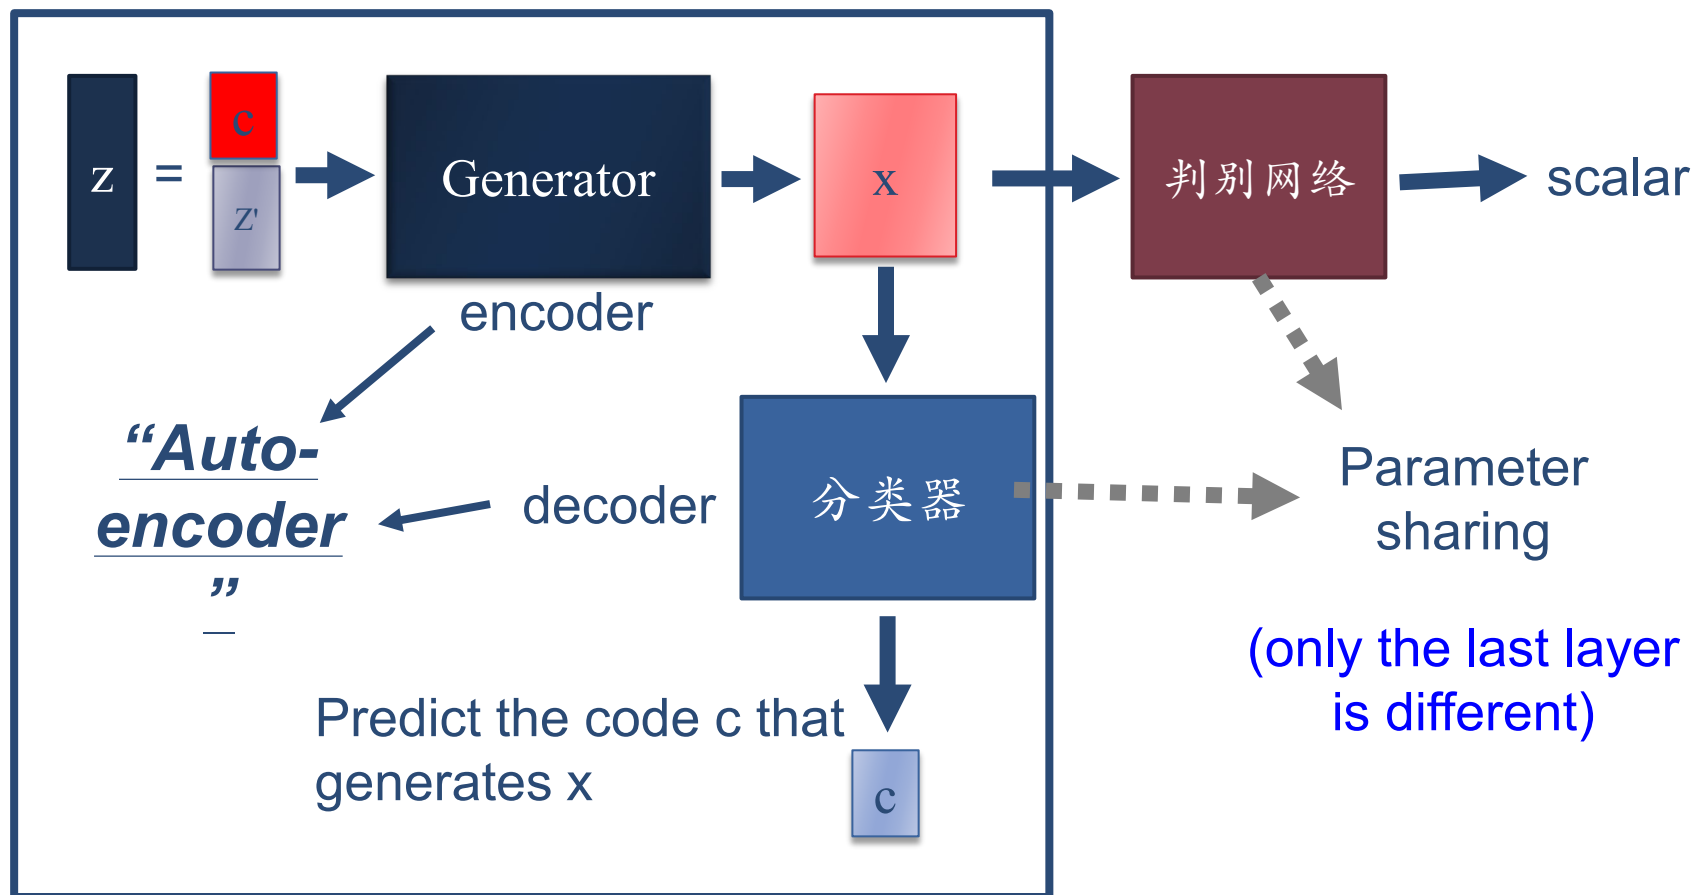



Conditional GAN






InfoGAN







(a) Varying c_1 on InfoGAN (Digit type)



(b) Varying c_1 on regular GAN (No clear meaning)



(c) Varying c_2 from -2 to 2 on InfoGAN (Rotation)



(d) Varying c_3 from -2 to 2 on InfoGAN (Width)



(a) Rotation

(b) Width



(c) Lighting

(d) Wide or Narrow